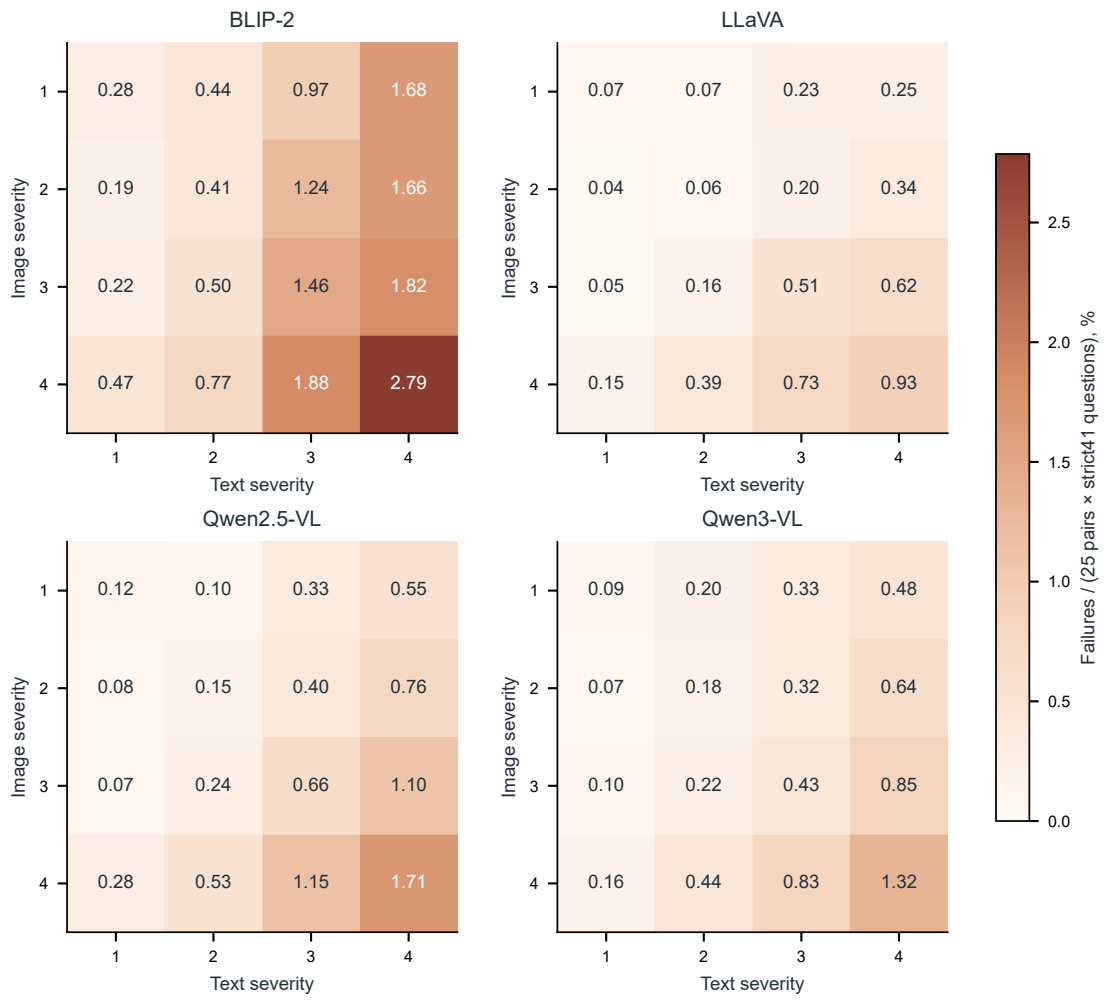
BLIP-2
LLaVA
Qwen2.5-VL
Qwen3-VL
Image severity
Text severity
1
2
3
4
0.28 0.44 0.97 1.68
0.19 0.41 1.24 1.66
0.22 0.50 1.46 1.82
0.47 0.77 1.88 2.79
0.07 0.07 0.23 0.25
0.04 0.06 0.20 0.34
0.05 0.16 0.51 0.62
0.15 0.39 0.73 0.93
0.12 0.10 0.33 0.55
0.08 0.15 0.40 0.76
0.07 0.24 0.66 1.10
0.28 0.53 1.15 1.71
0.09 0.20 0.33 0.48
0.07 0.18 0.32 0.64
0.10 0.22 0.43 0.85
0.16 0.44 0.83 1.32
Failures / (25 pairs × strict41 questions), %
0.0
0.5
1.0
1.5
2.0
2.5